

Università di Brescia

DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

*Corso di Laurea
in Ingegneria Informatica*

Relazione Finale

**TECNICHE DI VISIONE ARTIFICIALE PER LA
RILEVAZIONE PRECOCE DELL'ANNEGAMENTO**

Relatori:

Chiar.mo Dott. Alessandro Gnutti

Chiar.mo Prof. Riccardo Leonardi

Laureando:

Matteo Mottinelli

Matricola n. 745550

Anno Accademico 2025/2026

Sommario

Lorem ipsum dolor sit amet, consectetur adipiscing elit. In sollicitudin sagittis venenatis. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Sed elementum, augue sit amet convallis porttitor, arcu arcu egestas sapien, ut facilisis ipsum sapien lacinia risus. Praesent ultricies, erat volutpat porttitor vulputate, justo libero consectetur massa, at imperdiet arcu nulla vel justo. In hac habitasse platea dictumst. Maecenas a dui nisi. Aenean nec euismod tortor, sed vehicula erat, vestibulum ultrices mi egestas ac. Nullam sit amet urna sapien. Nunc eleifend elementum risus, elementum tincidunt sem scelerisque eu. Fusce commodo varius tincidunt.

Indice

1	Introduzione	1
1.1	Il problema dell’annegamento	1
1.1.1	Manifestazioni osservabili dell’annegamento	3
1.2	Obiettivi dell’elaborato	5
1.3	Struttura dell’elaborato	7
2	Fondamenti Teorici	8
2.1	Il Drowning Early Warning System	8
2.1.1	Rilevazione, separazione e tracciamento dei bagnanti	9
2.1.2	Estrazione dei descrittori comportamentali	10
2.1.3	Classificazione del comportamento	13
2.2	Il modello You Only Look Once	13
2.2.1	Rappresentazione delle predizioni	14
2.2.2	La funzione di loss di YOLO	15
2.3	Motivazioni della sostituzione del modulo di rilevazione	17
3	Realizzazione del Dataset	19
3.1	Acquisizione del materiale video	19
3.1.1	Preparazione delle registrazioni	19
3.1.2	Configurazione e contenuto delle riprese	21
3.2	Pre-processing dei filmati	21
3.3	Realizzazione del dataset YOLO-SEG	22
3.3.1	Generazione automatica delle maschere	22
3.3.2	Definizione della classe	23
3.3.3	Revisione e controllo della qualità	23
3.3.4	Esportazione nel formato YOLO Segmentation	24
3.4	Suddivisione nei set di training, validation e test	24
3.5	Conversione nel formato YOLO Detection	25
3.6	Vantaggi e limiti del dataset	26
4	Fine-tuning e Analisi dei Risultati	28
4.1	Selezione del modello e delle taglie	28
4.2	Configurazione del processo di fine-tuning	29
4.2.1	Prima configurazione	30
4.2.2	Seconda configurazione	30
4.3	Tecniche di data augmentation	30

4.4	Protocollo e metriche di valutazione	31
4.5	Analisi del processo di addestramento	32
4.6	Risultati sul test set	33
4.6.1	Object detection	33
4.6.2	Segmentazione di istanza	33
4.6.3	Effetto complessivo del fine-tuning	34
4.7	Idoneità per un'applicazione real-time	34
4.8	Considerazioni conclusive	35
5	Integrazione nella Pipeline Esistente	36
6	Conclusioni	37

Elenco delle figure

1.1	Manifestazioni osservabili dell'annegamento attivo	4
1.2	Perimetro dell'elaborato	6
2.1	Fasi principali della <i>pipeline</i> DEWS	8
2.2	Processo di <i>blob splitting</i> in DEWS	10
2.3	Relazioni tra i descrittori comportamentali di DEWS	12
2.4	Modelli HMM per la classificazione del comportamento	13
2.5	Rappresentazione delle predizioni di YOLOv1	14
2.6	Architettura di YOLOv1	15
3.1	Configurazione delle telecamere e inquadrature ottenute	20
3.2	Fasi principali del <i>pre-processing</i>	22
3.3	Processo di annotazione del <i>dataset</i> YOLO-SEG	23
3.4	Esempio di correzione delle annotazioni	24
3.5	Confronto tra annotazioni YOLO-SEG e YOLO Detection	26
3.6	Esempi della variabilità del <i>dataset</i>	27

Elenco delle tabelle

1.1	Annegamenti in piscina per fascia d'età e sesso (2022–2026)	2
1.2	Annegamenti in piscina per fascia d'età e tipologia (2022–2026)	2
1.3	Confronto tra annegamento attivo e passivo	5
2.1	Confronto tra il rilevatore originale di DEWS e YOLO	18
3.1	Suddivisione del <i>dataset</i>	25

Elenco dei listati

3.1	Riga completa relativa all'istanza 5 del fotogramma 482 del video 126 nel formato YOLO Segmentation	24
3.2	Riga completa relativa all'istanza 5 del fotogramma 482 del video 126 nel formato YOLO Detection	25

Capitolo 1

Introduzione

L’annegamento rappresenta ancora oggi un problema di rilevanza mondiale, nonostante i progressi compiuti nell’ambito della prevenzione, della sorveglianza e delle tecniche di soccorso. Secondo l’ultimo *report* pubblicato dall’Organizzazione Mondiale della Sanità (OMS), datato al 1° maggio 2026, ogni anno si registrano a livello globale circa 300 000 decessi riconducibili all’annegamento [9]. Il fenomeno assume una rilevanza ancora maggiore se si considera la distribuzione delle vittime per fascia d’età: l’annegamento si colloca infatti tra le principali cause di morte nell’infanzia, risultando la quarta causa di morte per i bambini di età compresa tra 1 e 4 anni e la terza per quelli appartenenti alla fascia tra 5 e 14 anni [9].

Questi dati evidenziano come l’annegamento non costituisca un fenomeno marginale, ma un problema di sicurezza che interessa in modo particolarmente significativo le fasce più giovani della popolazione. La prevenzione assume pertanto un ruolo centrale e comprende sia interventi di carattere organizzativo e infrastrutturale, sia l’adozione di strumenti tecnologici capaci di supportare il personale addetto alla sorveglianza [9, 26].

Accanto agli interventi di prevenzione, assume quindi particolare rilievo la tempestività con cui una situazione di pericolo viene riconosciuta e vengono avviate le operazioni di soccorso. Da questa esigenza deriva un interesse collettivo per lo sviluppo di sistemi automatici capaci di affiancare la normale attività di vigilanza, analizzando continuamente quanto avviene all’interno della vasca e segnalando situazioni potenzialmente compatibili con un episodio di crisi [16, 26].

Il presente elaborato si colloca dunque in questo ambito e affronta, in particolare, il problema della rilevazione automatica dei bagnanti, all’interno di un più ampio sistema destinato alla rilevazione precoce di potenziali fenomeni di annegamento.

1.1 Il problema dell’annegamento

Pur offrendo un inquadramento generale del fenomeno, i dati globali non esauriscono gli aspetti rilevanti ai fini di questo lavoro, che si concentra sugli incidenti avvenuti nelle piscine. Rispetto alle acque libere, le piscine costituiscono ambienti più controllati e, proprio per questo, particolarmente adatti all’impiego di sistemi di videosorveglianza automatizzata [26].

Nel contesto italiano, il rapporto sugli annegamenti pubblicato da Federalberghi nel giugno 2026, stima che tra il 1° gennaio 2022 e il 31 maggio 2026 si siano verificati

complessivamente 63 annegamenti in piscina, corrispondenti a una media di circa 14 casi all'anno. Il dato comprende differenti tipologie di struttura, tra cui piscine di centri sportivi, parchi acquatici, piscine comunali, stabilimenti termali, strutture ricettive e abitazioni private [10].

La stessa analisi evidenzia una particolare incidenza del fenomeno sulle fasce di età più giovani. Dei 63 casi considerati, il 57,2% degli episodi censiti riguarda soggetti con un'età inferiore a quindici anni [10]. Tali dati forniscono un'indicazione significativa della persistenza del problema anche all'interno di ambienti strutturati e sottoposti a forme di sorveglianza.

Tabella 1.1: Annegamenti avvenuti nelle piscine italiane da gennaio 2022 a maggio 2026, per fascia d'età e sesso

Fascia d'età	Maschi	%	Femmine	%	Totale	%
Sino a 4 anni	15	31,9%	2	12,5%	17	27,0%
5–14 anni	12	25,5%	7	43,8%	19	30,2%
15–24 anni	7	14,9%	1	6,3%	8	12,7%
25–44 anni	6	12,8%	0	0,0%	6	9,5%
45–64 anni	2	4,3%	2	12,5%	4	6,3%
65 anni e oltre	5	10,6%	4	25,0%	9	14,3%
Totale	47	100,0%	16	100,0%	63	100,0%
%	74,6%		25,4%		100,0%	

Tabella 1.2: Annegamenti avvenuti nelle piscine italiane da gennaio 2022 a maggio 2026, per fascia d'età e tipologia di piscina

Fascia d'età	Aperte al pubblico	Annesse ad abitazioni	Riservate agli alloggiati	Totale	%
Sino a 4 anni	4	11	2	17	27,0%
5–14 anni	13	0	6	19	30,2%
15–24 anni	2	3	3	8	12,7%
25–44 anni	2	3	1	6	9,5%
45–64 anni	3	1	0	4	6,3%
65 anni e oltre	4	0	5	9	14,3%
Totale	28	18	17	63	100,0%
%	44,4%	28,6%	27,0%	100,0%	

La presenza di personale addetto alla vigilanza rappresenta naturalmente la principale forma di prevenzione all'interno delle piscine pubbliche.¹ L'utilizzo di un sistema automatico di rilevazione non deve quindi essere interpretato come una sostituzione del bagnino, bensì come un ulteriore livello di sicurezza in grado di affiancarne l'attività.

¹La norma UNI EN ISO 20380:2018 stabilisce che i sistemi di visione computerizzata sono progettati per integrare il bagnino o il personale addestrato e non per ridurre la sorveglianza umana [26].

L'utilità di un simile strumento deriva anche dalle peculiarità con cui può manifestarsi un episodio di annegamento. La rappresentazione comunemente associata a questo fenomeno, caratterizzata necessariamente da movimenti estremamente vistosi e da esplicite richieste di aiuto, non descrive infatti tutte le situazioni possibili [1, 3, 8]. Ai fini della progettazione di un sistema di visione artificiale è quindi necessario identificare quali caratteristiche del comportamento del bagnante possano essere effettivamente osservate attraverso una sequenza video.

1.1.1 Manifestazioni osservabili dell'annegamento

L'analisi viene condotta principalmente in senso visivo-comportamentale: l'obiettivo non è formulare una descrizione clinica del processo di annegamento, bensì individuare i segnali esteriori osservabili da un operatore o acquisibili mediante una telecamera, rilevanti per un sistema automatico di rilevazione.

Le assunzioni comportamentali utilizzate all'interno del progetto derivano principalmente dagli studi di Frank Pia sul comportamento dei soggetti in difficoltà in acqua [1, 3], successivamente ripresi nell'architettura di riferimento adottata nel presente lavoro [11, 16]. Questi studi hanno avuto un ruolo centrale nella definizione di indicatori visivi utilizzabili per distinguere una normale attività natatoria da una situazione di crisi. Studi osservazionali e revisioni più recenti hanno tuttavia evidenziato una maggiore varietà delle manifestazioni visibili e una disponibilità ancora limitata di evidenze empiriche sui segnali precoci [7, 8]. Gli indicatori descritti di seguito devono quindi essere intesi come il modello di riferimento adottato dal sistema in analisi, non come criteri sufficienti a riconoscere ogni possibile episodio.

Una prima distinzione rilevante riguarda i concetti di *distress* e di *drowning*. Nel primo caso il soggetto si trova in una situazione di difficoltà e non è in grado di raggiungere autonomamente una condizione di sicurezza, ad esempio a causa di stanchezza o di altre condizioni contingenti, ma conserva almeno parzialmente il controllo volontario dei propri movimenti [3, 11].

La situazione di annegamento propriamente detta presenta invece caratteristiche differenti. In particolare, gli indicatori descritti di seguito si riferiscono alla forma attiva dell'annegamento, nella quale il soggetto manifesta una risposta comportamentale istintiva, indicata come *instinctive drowning response*, associata alla condizione di soffocamento in acqua [1, 3, 16]. In questa fase il comportamento del soggetto non corrisponde necessariamente a una serie di azioni volontarie finalizzate alla richiesta di soccorso, ma è dominato dal tentativo di mantenere le vie respiratorie al di sopra della superficie.

Dal punto di vista osservabile, i principali indicatori considerati possono essere riassunti nei seguenti elementi [1, 3, 11, 8]:

- il corpo tende ad assumere una posizione prevalentemente verticale rispetto alla superficie dell'acqua;
- lo spostamento orizzontale o diagonale del soggetto risulta limitato, dal momento che il movimento prodotto non è efficace nel generare una normale progressione natatoria;

- le braccia possono presentare movimenti ripetitivi, orientati lateralmente o frontalmente e caratterizzati dal tentativo di spingere verso il basso la superficie dell'acqua;
- l'azione degli arti inferiori può risultare assente, irregolare oppure inefficace ai fini della propulsione;
- la testa può risultare reclinata all'indietro, nel tentativo di mantenere bocca e naso al di sopra della superficie dell'acqua;
- il controllo volontario dei movimenti risulta fortemente limitato e il soggetto può non essere in grado di chiamare aiuto, poiché l'attività è principalmente finalizzata a mantenere la respirazione;
- il soggetto può alternare fasi di immersione ed emersione, fino all'eventuale completa sommersione;
- la fase di lotta in superficie costituisce un fenomeno temporalmente circoscritto: negli studi di Pia viene indicata una durata approssimativa compresa tra 20 e 60 secondi [1, 3].




Figura 1.1: Rappresentazione delle principali manifestazioni osservabili dell'annegamento attivo

Proprio quest'ultimo elemento evidenzia l'importanza della rilevazione precoce. Un sistema che sia in grado di individuare soltanto la presenza di un corpo ormai immobile sul fondo della vasca interviene infatti in una fase successiva rispetto a un sistema capace di osservare e interpretare il comportamento del bagnante mentre la crisi è ancora in corso. Questo principio costituisce una delle motivazioni alla base della scelta, nell'architettura di riferimento, di utilizzare telecamere installate al di sopra della piscina anziché affidarsi esclusivamente a dispositivi subacquei [12, 15, 16].

Accanto alla condizione di annegamento caratterizzata da una risposta attiva viene inoltre considerata una forma passiva. Con *passive drowning* si indica una condizione nella quale il soggetto, a seguito di una perdita di coscienza, scivola sott'acqua senza manifestare movimenti di lotta o richieste di aiuto evidenti. Tale condizione può presentarsi direttamente oppure costituire l'evoluzione di una fase inizialmente attiva, quando i movimenti di lotta cessano e il soggetto non riesce più a mantenersi in superficie. Le due condizioni risultano quindi profondamente differenti dal punto di vista della loro apparenza visiva: la prima è caratterizzata soprattutto dall'analisi del movimento e della postura, mentre nella seconda assumono maggiore importanza la progressiva sommersione e l'assenza di un'attività natatoria efficace [11, 13].

Tabella 1.3: Confronto tra le manifestazioni osservabili dell'annegamento attivo e passivo

Caratteristica	Annegamento attivo	Annegamento passivo
Stato di coscienza	Generalmente cosciente durante la fase di lotta	Perdita di coscienza
Manifestazioni osservabili	Movimenti di lotta e tentativo di mantenere le vie respiratorie emerse	Assenza di lotta e progressiva sommersione
Postura e movimento	Posizione prevalentemente verticale, movimenti laterali delle braccia e propulsione inefficace	Assenza di movimenti volontari; corpo immobile o soggetto a spostamenti indotti dall'acqua
Evoluzione	Può terminare con la completa sommersione ed evolvere nella forma passiva	Può manifestarsi direttamente oppure seguire una precedente fase attiva
Principali indicatori	Postura, movimenti ripetitivi e alternanza tra immersione ed emersione	Progressiva sommersione, immobilità e assenza di movimenti volontari

Tale variabilità costituisce uno dei principali problemi di un sistema automatico. Non esiste infatti un singolo attributo visivo sufficiente a identificare con certezza ogni possibile situazione di annegamento. Di conseguenza, la rilevazione di una crisi richiede l'osservazione congiunta di più caratteristiche e, soprattutto, della loro evoluzione nel tempo.

1.2 Obiettivi dell'elaborato


A partire dalle considerazioni precedenti, il presente elaborato affronta lo sviluppo di un sistema di visione artificiale per la rilevazione precoce di potenziali incidenti da annegamento in piscina. Il principale riferimento architetturale è il *Drowning Early Warning System* (DEWS), un sistema basato su telecamere sopraelevate e progettato per riconoscere i bagnanti e analizzarne il comportamento in tempo reale al fine di identificare situazioni di *water crisis* [16].

L'ambiente acquatico presenta difficoltà specifiche: riflessi, increspature, schizzi, ombre, movimenti delle corsie e variazioni dell'illuminazione modificano continuamente l'immagine anche in assenza di persone. Per gestire tale variabilità, il modulo di rilevazione originale impiega modelli statistici e diverse procedure deterministiche, la cui efficacia dipende dalla configurazione di numerosi parametri e soglie [14, 15, 16]. L'obiettivo principale dell'elaborato è valutare la modernizzazione di questo stadio mediante la famiglia di modelli *You Only Look Once* (YOLO) [18], trasferendo parte della complessità dalla progettazione manuale di regole a un modello appreso dai dati.

Una parte sostanziale del lavoro riguarda pertanto la realizzazione di un *dataset* specifico, ottenuto da registrazioni in un ambiente natatorio reale e comprendente sia normali attività in piscina sia simulazioni delle situazioni di interesse. Le sequenze sono state sottoposte a *pre-processing* e annotate, con un controllo manuale delle etichette. La suddivisione nei *set* di addestramento, validazione e *test* è stata definita con particolare attenzione, poiché qualità ed eterogeneità dei dati condizionano la capacità del modello di generalizzare a sequenze mai osservate.

Il secondo obiettivo consiste nel *fine-tuning* di YOLO sul *dataset* realizzato e nel confronto tra differenti configurazioni e dimensioni del modello, considerando gli iperparametri di addestramento e le tecniche di *data augmentation*. La valutazione comprende sia l'accuratezza nella rilevazione dei bagnanti sia le prestazioni computazionali: poiché il sistema è destinato a operare in tempo reale, la scelta deve bilanciare qualità della rilevazione e velocità di inferenza.

Un ulteriore obiettivo è verificare la compatibilità del nuovo *detector* con le fasi successive della *pipeline*. In DEWS, infatti, la rilevazione alimenta il tracciamento dei bagnanti e il calcolo dei descrittori comportamentali utilizzati per classificare l'attività osservata. L'integrazione di YOLO richiede dunque di stabilire quali informazioni siano direttamente disponibili, quali debbano essere adattate o ricostruite e quale sia l'impatto complessivo sulle prestazioni del sistema.



Elemento centrale dell'elaborato

Figura 1.2: Schema ad alto livello del perimetro dell'elaborato

Il progetto assume infine come riferimento la norma UNI EN ISO 20380:2018, che definisce requisiti e procedure di prova per i sistemi di visione computerizzata destinati alla rilevazione di incidenti da annegamento nelle piscine pubbliche [26]. La norma orienta le scelte progettuali, ma non viene perseguita né dichiarata una certificazione formale di conformità.

L'obiettivo è pertanto valutare l'idoneità di un modulo di *object detection* all'interno di un sistema più ampio, considerando l'accuratezza, la capacità di generalizzazione, la velocità di inferenza e la compatibilità con le elaborazioni successive.

1.3 Struttura dell’elaborato

Il presente elaborato è articolato in sei capitoli. Dopo questa introduzione, il Capitolo 2 espone i fondamenti teorici necessari, descrivendo l’architettura generale di DEWS, il funzionamento di YOLO e le motivazioni che hanno condotto alla sostituzione del modulo di rilevazione originale. Il Capitolo 3 illustra il processo di realizzazione del *dataset*, dalla fase di acquisizione fino all’annotazione e alla suddivisione nei diversi sottoinsiemi. Il Capitolo 4 descrive il processo di *fine-tuning* e analizza sperimentalmente le prestazioni dei modelli considerati. Il Capitolo 5 affronta l’integrazione del modello selezionato all’interno della *pipeline* esistente e ne valuta l’impatto. Infine, il Capitolo 6 riassume i risultati ottenuti, i limiti riscontrati e i possibili sviluppi futuri.

Capitolo 2

Fondamenti Teorici

Il sistema sviluppato nel presente lavoro nasce dalla revisione di un'architettura esistente per la rilevazione precoce di situazioni di pericolo in piscina. Per comprendere le scelte progettuali adottate è quindi necessario descrivere, seppure sinteticamente, il funzionamento del sistema di riferimento e le informazioni scambiate tra le sue diverse fasi. Il capitolo introduce dapprima il *Drowning Early Warning System* (DEWS); successivamente presenta i principi alla base di *You Only Look Once* (YOLO) e conclude discutendo le motivazioni che hanno condotto alla sostituzione del modulo di rilevazione originale.

2.1 Il Drowning Early Warning System

DEWS è un sistema di videosorveglianza progettato per individuare precocemente comportamenti compatibili con una situazione di crisi in acqua. L'architettura impiega una rete di telecamere installate in posizione sopraelevata intorno alla piscina. Ciascuna telecamera osserva una regione locale della vasca, parzialmente sovrapposta a quelle adiacenti, mentre l'unione delle inquadrature assicura la copertura dell'intera area di interesse. Questa configurazione permette di analizzare il comportamento del soggetto durante le fasi iniziali della crisi e, compatibilmente con le condizioni di visibilità attraverso l'acqua, di continuare a osservarlo anche durante una sommersione. L'efficacia della rilevazione in questa seconda condizione dipende tuttavia dai riflessi, dall'agitazione della superficie, dalla trasparenza dell'acqua e dalla profondità del soggetto [16].




Figura 2.1: Schema delle tre fasi principali della *pipeline* DEWS

La *pipeline* può essere ricondotta a tre fasi principali. La prima individua i bagnanti nell'immagine, separa le *silhouette* che risultano connesse e associa nel tempo le osservazioni appartenenti allo stesso soggetto generando delle tracce. La seconda trasforma la storia di ciascuna traccia in un insieme compatto di descrittori geometrici, cinematici e

cromatici. La terza combina tali descrittori e ne analizza l'evoluzione temporale per distinguere il nuoto ordinario, il mantenimento volontario della posizione verticale e una potenziale situazione di crisi [16].

2.1.1 Rilevazione, separazione e tracciamento dei bagnanti

La rilevazione dei bagnanti è resa complessa dalla natura dello sfondo. La superficie dell'acqua non è statica: onde, riflessi, ombre, schizzi e spostamenti apparenti delle corsie producono variazioni anche quando nessun soggetto attraversa una determinata regione. Per limitare i falsi positivi, DEWS suddivide l'immagine in blocchi e rappresenta il *background* attraverso regioni cromaticamente omogenee. I colori sono espressi nello spazio CIE $L^*a^*b^*$ e i modelli appartenenti a blocchi vicini vengono inclusi nella ricerca, così da tollerare piccoli spostamenti degli elementi dello sfondo [14, 15].

Il confronto tra l'immagine corrente e il modello regionale produce una misura di compatibilità con il *background*. Due soglie, una bassa e una alta, vengono combinate secondo un principio di isteresi: la prima conserva la *silhouette* estesa del soggetto, mentre la seconda identifica i nuclei nei quali l'evidenza di *foreground* è più forte. Le componenti connesse sufficientemente grandi della maschera risultante costituiscono i *blob* candidati. Inoltre, un modello cromatico del *foreground*, aggiornato durante il tracciamento, contribuisce a recuperare le parti del bagnante il cui colore è simile a quello dell'acqua [15, 16].

Quando più persone si trovano a contatto nell'immagine, le rispettive *silhouette* possono confluire in un unico *blob*. Il procedimento di *blob splitting* valuta allora diverse ipotesi sul numero di soggetti presenti e approssima ciascun soggetto mediante un'ellisse. Indicando con $\mathbf{M}^t$ la maschera del *blob* osservata all'istante t e con $\Gamma^t = \{\gamma_1, \dots, \gamma_k\}$ un'ipotesi composta da k ellissi, il termine di verosimiglianza impiegato nel punteggio di validità è definito come

$$P(\mathbf{M}^t | \Gamma^t) \propto \sum_{i=1}^k \frac{A_{\gamma_i}^{bg} + A_{\gamma_i}^{ov}}{A_{\gamma_i}^{fg}}. \quad (2.1)$$

Le quantità $A_{\gamma_i}^{bg}$ e $A_{\gamma_i}^{fg}$ rappresentano rispettivamente il numero di *pixel* di *background* e di *foreground* racchiusi dall'ellisse γ_i , mentre $A_{\gamma_i}^{ov}$ indica i *pixel* di *foreground* appartenenti alla zona di sovrapposizione con le altre ellissi. Il rapporto diminuisce quando le ellissi coprono una porzione maggiore della *silhouette* e aumenta quando includono sfondo o si sovrappongono eccessivamente. Le configurazioni vengono raffinate a partire dalla distribuzione dei *pixel* di *foreground*; ripetendo il procedimento per differenti valori di k , viene selezionato come numero più plausibile di bagnanti quello associato al minimo punteggio complessivo di validità, nel quale viene considerata anche la continuità con il fotogramma precedente. Le osservazioni ottenute vengono infine associate alle tracce esistenti sulla base della posizione prevista e della compatibilità spaziale. Il tracciamento non serve soltanto a mantenere l'identità del soggetto, ma rende disponibile la storia temporale necessaria alla fase successiva [16].




Figura 2.2: Processo di *blob splitting* adottato in DEWS: inizializzazione, adattamento delle ellissi e risultato finale. Tratto da [16, Fig. 8]

2.1.2 Estrazione dei descrittori comportamentali

Per ogni traccia, DEWS ricava dapprima alcune proprietà di basso livello dalla *silhouette*: area, centroide, matrice di covarianza spaziale, orientamento e assi dell'ellisse equivalente, colore medio e saturazione media. Queste quantità descrivono il soggetto in un singolo istante, ma non sono sufficienti a caratterizzarne il comportamento. Il sistema le aggrega pertanto lungo una finestra temporale locale $\mathcal{T}$ e costruisce sei descrittori di livello intermedio [16]:

$$\mathbf{x} = [M \ S \ P \ A \ Z \ U]^T \quad (2.2)$$

dove M rappresenta l'intervallo di movimento, S il prodotto delle velocità, P la variazione della postura, A la variazione dell'attività, Z la variazione della dimensione e U l'indice di sommersione. I descrittori traducono in misure numeriche alcuni degli indicatori osservabili discussi nel Capitolo 1; il loro significato dipende tuttavia dal contesto e nessuno di essi, considerato isolatamente, permette di stabilire con certezza la presenza di una crisi.

Intervallo di movimento. Sia $\mathbf{c}_t$ il centroide della *silhouette* all'istante t . Il *movement range* misura la massima distanza fra due posizioni registrate nella finestra temporale:

$$M = \max_{i,j \in \mathcal{T}} \|\mathbf{c}_i - \mathbf{c}_j\|_2. \quad (2.3)$$

Un soggetto che nuota lungo la vasca tende a coprire uno spazio maggiore e presenta quindi, in generale, un valore di M più elevato. Un bagnante che lotta per mantenersi in superficie o affonda quasi sul posto può invece produrre un intervallo più ridotto. Anche il mantenimento volontario della posizione verticale, tuttavia, è caratterizzato da uno spostamento limitato: il descrittore non può dunque essere interpretato mediante una singola soglia.

Prodotto delle velocità. La velocità del centroide può essere stimata come $\mathbf{v}_t = (\mathbf{c}_t - \mathbf{c}_{t-1})/\Delta t$. Indicando con $\theta_t \in [0, \pi]$ l'angolo compreso tra $\mathbf{v}_{t-1}$ e $\mathbf{v}_t$, lo *speed product* è definito come

$$S_t = \|\mathbf{v}_{t-1}\|_2 \|\mathbf{v}_t\|_2 \cos\left(\frac{\theta_t}{2}\right). \quad (2.4)$$

Il prodotto delle norme assume valori maggiori in presenza di un movimento rapido e persistente. Il termine angolare riduce invece il contributo quando la direzione cambia bruscamente; la divisione per due mantiene il coseno non negativo nell'intervallo considerato. La misura combina pertanto intensità e coerenza direzionale del movimento, penalizzando le traiettorie maggiormente irregolari.

Variazione della postura. L'orientamento del bagnante viene approssimato dall'angolo ϑ_t formato dall'asse principale dell'ellisse equivalente con l'asse orizzontale dell'immagine. Posti

$$\vartheta_{\min} = \min_{t \in \mathcal{T}} \vartheta_t, \quad \vartheta_{\max} = \max_{t \in \mathcal{T}} \vartheta_t, \quad (2.5)$$

la *posture variation* corrisponde all'ampiezza dell'intervallo osservato:

$$P = \vartheta_{\max} - \vartheta_{\min}. \quad (2.6)$$

Movimenti ripetitivi degli arti e variazioni della porzione di corpo visibile possono modificare continuamente l'ellisse stimata, facendo aumentare P . La misura descrive quindi la variazione dell'orientamento nella finestra e non, presa singolarmente, la verticalità del soggetto.

Variazione dell'attività. Per ogni istante si considera il rapporto fra l'area dell'ellisse equivalente e l'area effettiva della *silhouette*:

$$r_t = \frac{A_{\text{ellisse},t}}{A_{\text{silhouette},t}}. \quad (2.7)$$

La *activity variation* è la differenza fra il valore massimo e quello minimo del rapporto nella finestra temporale:

$$A = \max_{t \in \mathcal{T}} r_t - \min_{t \in \mathcal{T}} r_t. \quad (2.8)$$

L'estensione e la contrazione degli arti modificano la relazione tra la forma reale e la sua approssimazione ellittica. Una variazione elevata può quindi essere associata a un'attività intensa o irregolare, ma può derivare anche da normali movimenti natatori o da imprecisioni nella segmentazione.

Variazione della dimensione. Siano $s_{\max}$, $s_{\min}$ e $\bar{s}$ rispettivamente l'area massima, minima e media della *silhouette* nella finestra. La *size variation* normalizza l'escursione dell'area rispetto alla dimensione media:

$$Z = \frac{s_{\max} - s_{\min}}{\bar{s}}. \quad (2.9)$$

La normalizzazione rende confrontabili, almeno in prima approssimazione, soggetti che occupano porzioni diverse dell'immagine. Z può crescere quando gli arti vengono estesi e contratti, quando il corpo entra ed esce parzialmente dall'acqua o quando le perturbazioni della superficie frammentano la *silhouette* rilevata.

Indice di sommersione. DEWS utilizza infine la saturazione cromatica come indicazione indiretta della profondità apparente del soggetto. Sia $\bar{q}_t$ la saturazione media della *silhouette* all'istante corrente e sia $q_{\min}$ il minimo valore medio registrato dall'inizio della traccia. Il *submersion index* è definito da

$$U_t = \bar{q}_t - q_{\min}. \quad (2.10)$$

Secondo il modello adottato dagli autori, un corpo osservato attraverso uno strato d'acqua maggiore tende ad assumere una dominante più blu e una saturazione più elevata. Un valore alto di U_t suggerisce quindi una condizione più sommersa rispetto al momento in cui il soggetto è apparso meno immerso. La misura dipende però dall'illuminazione, dal colore dell'acqua e dalla qualità della segmentazione [16].

I valori assunti dai sei descrittori possono sovrapporsi significativamente tra attività differenti. Ad esempio, sia una crisi sia il mantenimento volontario della posizione verticale possono produrre uno spostamento ridotto, mentre un nuoto vigoroso può generare notevoli variazioni della *silhouette*. Proprio questa sovrapposizione motiva l'impiego di un classificatore capace di combinare le caratteristiche e di un successivo modello temporale [16].




Figura 2.3: Relazioni tra i sei descrittori comportamentali per le classi *swimming*, *treading* e *water crisis*. I diagrammi evidenziano la sovrapposizione tra le distribuzioni delle diverse attività. Tratto da [16, Fig. 6]

2.1.3 Classificazione del comportamento

DEWS riconduce il comportamento osservato a tre classi: *water crisis*, *treading* e *swimming*. La prima riunisce le situazioni che devono condurre a un allarme, mentre le altre due rappresentano rispettivamente il mantenimento volontario della posizione in acqua e le normali attività natatorie. I sei descrittori vengono inizialmente combinati mediante un *Reduced Model*, ossia un classificatore che costruisce una base polinomiale ridotta e ne stima i coefficienti attraverso un problema ai minimi quadrati. In questo modo è possibile modellare relazioni non lineari tra caratteristiche che, considerate separatamente, non risultano sufficientemente discriminanti [16].

L'uscita istantanea del classificatore alimenta poi tre *Hidden Markov Model*, uno per ciascun comportamento. Gli HMM valutano la sequenza recente delle osservazioni e rappresentano la persistenza degli stati e le transizioni tipiche nel tempo. La decisione non determina immediatamente l'attivazione dell'allarme: quando il modello associato alla crisi risulta il più probabile, un contatore viene incrementato; in caso contrario viene decrementato senza assumere mai valori negativi. Soltanto un'evidenza sufficientemente persistente conduce prima a una condizione di attenzione e poi allo stato di allarme. Quest'ultimo passaggio riduce la sensibilità a classificazioni isolate e completa la terza fase della *pipeline* [16].




Figura 2.4: Modelli HMM impiegati da DEWS per descrivere le transizioni di stato: (a) crisi in acqua, (b) nuoto e (c) mantenimento volontario della posizione. Tratto da [16, Fig. 7]

2.2 Il modello You Only Look Once

L'obiettivo dell'*object detection* è individuare le istanze degli oggetti di interesse presenti in un'immagine, determinandone contemporaneamente la classe e la posizione. Il risultato non è quindi una sola etichetta riferita all'intero fotogramma, ma un insieme di istanze, ciascuna descritta da una classe e da una regione spaziale, generalmente rappresentata mediante una *bounding box*.

Gli approcci tradizionali a più stadi separano la generazione delle regioni candidate dalla loro classificazione. YOLO affronta invece la rilevazione come un unico problema di regressione, mappando direttamente i *pixel* dell'immagine nelle coordinate delle regioni e nelle rispettive probabilità di classe. L'intera immagine viene elaborata una sola volta da una rete neurale, da cui l'espressione *You Only Look Once*. Questa impostazione *single-stage* consente al modello di utilizzare il contesto globale della scena

e, soprattutto, evita di eseguire ripetutamente un classificatore su un grande numero di regioni proposte [18].

Nel presente lavoro viene adottata una variante di YOLO per la segmentazione di istanza, indicata nel seguito come YOLO-SEG. Oltre a localizzare ciascun bagnante, il modello associa all'istanza una maschera che ne delimita la *silhouette* a livello di *pixel*. Tale rappresentazione è particolarmente adatta all'integrazione con DEWS, poiché rende direttamente disponibile la forma del soggetto necessaria al calcolo dei descrittori comportamentali. La formulazione di YOLOv1 descritta di seguito mantiene comunque un valore fondativo per comprendere il funzionamento generale della famiglia di modelli.

2.2.1 Rappresentazione delle predizioni

Nella formulazione originaria, l'immagine viene suddivisa in una griglia di $S \times S$ celle. La cella che contiene il centro di un oggetto è responsabile della sua predizione. Ogni cella produce B *bounding box*; per ciascuna vengono stimate le coordinate del centro (x, y) , la larghezza w , l'altezza h e un valore di confidenza C . Le coordinate del centro sono espresse relativamente ai limiti della cella, mentre larghezza e altezza sono normalizzate rispetto alle dimensioni dell'immagine [18].

La confidenza rappresenta congiuntamente la probabilità che la regione contenga un oggetto e la qualità della sua localizzazione:

$$C = \Pr(\text{Object}) \text{IoU}(B_{\text{pred}}, B_{\text{gt}}), \quad (2.11)$$

dove B_{pred} e B_{gt} indicano rispettivamente la regione predetta e quella annotata, mentre l'*Intersection over Union* è definita come

$$\text{IoU}(B_{\text{pred}}, B_{\text{gt}}) = \frac{|B_{\text{pred}} \cap B_{\text{gt}}|}{|B_{\text{pred}} \cup B_{\text{gt}}|}. \quad (2.12)$$




Figura 2.5: Rappresentazione delle predizioni di YOLOv1: griglia di ingresso, regioni con i relativi valori di confidenza, probabilità di classe e rilevazioni finali. Tratto da [18, Fig. 2]

La IoU assume valore nullo quando le regioni non si intersecano e raggiunge il valore unitario quando coincidono. A livello di cella, YOLOv1 predice inoltre le probabilità condizionate $\Pr(c \mid \text{Object})$ per ciascuna classe c . Durante l'inferenza, il prodotto tra queste probabilità e la confidenza assegna a ogni regione un punteggio specifico per classe. Le predizioni ridondanti vengono successivamente filtrate, mantenendo le regioni più affidabili fra quelle fortemente sovrapposte [18].

La rete originaria proposta da Redmon *et al.* è composta da 24 strati convoluzionali seguiti da due strati *fully connected*. Gli strati convoluzionali estraggono progressivamente rappresentazioni dell'immagine, mentre l'uscita finale organizza in un unico tensore tutte le coordinate, le confidenze e le probabilità di classe [18].




Figura 2.6: Architettura originaria di YOLOv1, composta da 24 strati convoluzionali e due strati *fully connected*. Tratto da [18, Fig. 3]

2.2.2 La funzione di loss di YOLO

L'addestramento richiede una funzione obiettivo che penalizzi simultaneamente errori di localizzazione, di confidenza e di classificazione. Nella formulazione di YOLOv1 tali contributi sono espressi mediante una somma di errori quadratici. Nel seguito, i indicizza le S^2 celle della griglia, mentre j identifica uno dei B predittori di regione associati a ciascuna cella.¹ Le grandezze contrassegnate dall'accento circonflesso corrispondono alle predizioni prodotte dalla rete; le omologhe grandezze non accentate rappresentano invece i valori obiettivo. La funzione di *loss* completa è [18]:

¹La formula conserva gli estremi di sommatoria riportati nel lavoro originale. Con un'indicizzazione rigorosamente a base zero, le S^2 celle e i B predittori sarebbero numerati rispettivamente da 0 a $S^2 - 1$ e da 0 a $B - 1$; nell'articolo, invece, gli estremi S^2 e B indicano l'intero insieme degli elementi considerati.

$$\begin{aligned}
\mathcal{L}_{\text{YOLO}} = & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} [(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2] \\
& + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\
& + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\
& + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\
& + \sum_{i=0}^{S^2} \mathbb{K}_i^{\text{obj}} \sum_{c \in \mathcal{C}} (p_i(c) - \hat{p}_i(c))^2
\end{aligned} \tag{2.13}$$

I simboli $\mathbb{K}$ sono funzioni indicatrici e assumono valore uno quando la condizione specificata dagli indici e dall'apice è verificata, e zero altrimenti. In particolare, $\mathbb{K}_i^{\text{obj}}$ vale uno quando la cella i contiene il centro di un oggetto. L'indicatore $\mathbb{K}_{ij}^{\text{obj}}$ vale invece uno quando, oltre a essere presente un oggetto nella cella i , il predittore j è quello responsabile della sua localizzazione; durante l'addestramento tale responsabilità è assegnata al predittore la cui regione presenta la IoU più elevata con l'annotazione. Infine, $\mathbb{K}_{ij}^{\text{noobj}}$ vale uno quando il predittore j della cella i non è responsabile della predizione di un oggetto. Quest'ultima condizione può verificarsi anche in una cella contenente un oggetto, poiché uno solo dei B predittori viene designato come responsabile. Le quantità $p_i(c)$ e $\hat{p}_i(c)$ rappresentano, rispettivamente, la probabilità condizionata obiettivo e quella predetta per la classe $c \in \mathcal{C}$.

I cinque termini dell'Equazione 2.13 possono essere ricondotti a tre componenti principali.

Errore di localizzazione. I primi due termini penalizzano gli errori nelle coordinate e nelle dimensioni delle regioni responsabili di un oggetto. Il coefficiente λ_{coord} aumenta il peso di questa componente rispetto alle altre; nella configurazione originaria viene posto pari a 5. Per larghezza e altezza non viene confrontato direttamente il valore, ma la sua radice quadrata. In questo modo uno stesso scostamento assoluto assume un peso relativamente maggiore per una regione piccola e minore per una regione grande, riducendo la dipendenza dell'errore dalla scala della *bounding box*.

Errore di confidenza. Il terzo e il quarto termine misurano la differenza tra confidenza predetta e confidenza obiettivo. I due casi sono separati perché la maggior parte delle celle di un'immagine non contiene oggetti: attribuire lo stesso peso a tutte le predizioni negative farebbe dominare il loro contributo e spingerebbe la rete a produrre confidenze prossime a zero. YOLOv1 introduce pertanto $\lambda_{\text{noobj}} = 0,5$ per ridurre il peso delle regioni prive di un oggetto assegnato. Quando un predittore è responsabile, la confidenza obiettivo incorpora la sovrapposizione con la regione reale; l'errore riflette quindi sia la presenza dell'oggetto sia la qualità della localizzazione.

Errore di classificazione. L'ultimo termine confronta le probabilità condizionate di classe e viene calcolato soltanto nelle celle che contengono un oggetto. Le celle di solo sfondo non contribuiscono quindi all'errore di classificazione. Poiché la classe è associata alla cella e non a ciascuna singola regione, nella formulazione originaria i B predittori della stessa cella condividono il medesimo vettore di probabilità.

La somma quadratica rende l'ottimizzazione unificata e consente di apprendere congiuntamente tutte le componenti della rilevazione, ma non coincide direttamente con la metrica utilizzata per valutare un *detector*. Gli stessi autori osservano inoltre che il bilanciamento fra localizzazione e classificazione e la gestione degli oggetti piccoli costituiscono limiti della prima formulazione [18]. La *loss* descritta ha pertanto un valore fondativo per comprendere YOLOv1; le versioni successive della famiglia hanno introdotto architetture e funzioni obiettivo differenti.

2.3 Motivazioni della sostituzione del modulo di rilevazione

Il primo modulo di DEWS affronta esplicitamente le difficoltà dell'ambiente acquatico e mantiene il vantaggio di un procedimento deterministico, nel quale ogni passaggio può essere ricondotto a una regola o a un parametro interpretabile. Questa caratteristica comporta tuttavia una notevole complessità operativa, poiché il metodo richiede una calibrazione specifica rispetto alla scena. Variazioni dell'inquadratura, dell'illuminazione o delle caratteristiche della piscina possono quindi richiedere una nuova regolazione dei parametri [14, 15, 16].

Un secondo limite riguarda la separazione delle istanze. Nel metodo originale i bagnanti vengono ricavati come componenti connesse della maschera di *foreground*; quando le *silhouette* si uniscono, il sistema deve stimare quante persone appartengano al *blob* e valutare iterativamente diverse configurazioni di ellissi. Il procedimento aumenta il costo computazionale e diviene più fragile al crescere dell'affollamento. YOLO produce invece direttamente un insieme di regioni candidate distinte e associa a ciascuna una confidenza. Ciò elimina la necessità di uno stadio esplicito di *blob splitting*, pur senza risolvere in modo assoluto il problema delle occlusioni tra persone [16, 18].

La sostituzione trasferisce inoltre parte della complessità dalla progettazione manuale delle regole all'apprendimento dai dati. Attraverso il *fine-tuning*, il modello può apprendere le caratteristiche visive dei bagnanti nelle condizioni rappresentate dal *dataset*, senza richiedere la definizione di un modello cromatico specifico per ogni elemento della scena. L'elaborazione *single-stage* e l'esecuzione efficiente su acceleratori *hardware* rendono YOLO un candidato adatto a un'applicazione con vincoli temporali stringenti (esecuzione in *real-time*) [18].

Il cambiamento presenta anche alcune contropartite. Un modello appreso è meno direttamente spiegabile del procedimento deterministico e dipende dalla disponibilità di dati numerosi, correttamente annotati e sufficientemente eterogenei. Se le condizioni operative differiscono da quelle osservate durante l'addestramento, la capacità di generalizzazione può ridursi. La costruzione del *dataset*, il controllo delle annotazioni e la configurazione del *fine-tuning* diventano quindi parti essenziali del sistema, anziché attività accessorie.

Tabella 2.1: Confronto qualitativo tra il modulo di rilevazione originale di DEWS e YOLO

Caratteristica	Modulo originale DEWS	YOLO
Calibrazione	Richiede la regolazione di modelli, soglie e parametri in funzione della scena osservata.	Trasferisce gran parte della configurazione al processo di addestramento e di <i>fine-tuning</i> .
Informazioni prodotte	Genera maschere di <i>foreground</i> , componenti connesse e modelli ellittici dei soggetti.	Restituisce direttamente regioni o maschere, classi e valori di confidenza.
Gestione dell'affollamento	Separa esplicitamente le <i>silhouette</i> connesse mediante il processo iterativo di <i>blob splitting</i> .	Predice più istanze in un'unica elaborazione, pur rimanendo sensibile alle occlusioni.
Costo computazionale	Comprende più operazioni deterministiche e una ricerca iterativa delle configurazioni di ellissi.	Esegue la rilevazione mediante una singola valutazione della rete e beneficia dell'impiego di acceleratori <i>hardware</i> .
Spiegabilità	Ogni passaggio dipende da regole e parametri direttamente interpretabili.	Le decisioni dipendono da rappresentazioni apprese e risultano meno direttamente interpretabili.
Dipendenza dai dati	Riduce la necessità di dati annotati, ma richiede una configurazione accurata rispetto alla scena.	Richiede un insieme di addestramento annotato, rappresentativo ed eterogeneo.

In sintesi, l'impiego di YOLO mira a ottenere un modulo di rilevazione più facilmente adattabile, capace di gestire direttamente più istanze e compatibile con i requisiti di elaborazione in tempo reale. Il vantaggio atteso non consiste nell'eliminazione di ogni difficoltà, ma in una diversa distribuzione della complessità: dalle soglie e dalle procedure deterministiche specifiche della scena alla qualità dei dati e al processo di addestramento del modello. I capitoli successivi descriveranno come tale passaggio sia stato realizzato e ne valuteranno sperimentalmente le conseguenze.

Capitolo 3

Realizzazione del Dataset

L'impiego di un modello appreso per la rilevazione dei bagnanti trasferisce una parte rilevante della complessità del sistema alla costruzione dei dati di addestramento. Il *dataset* deve infatti rappresentare non soltanto l'aspetto dei soggetti, ma anche le condizioni che rendono difficile la loro individuazione: riflessi, schizzi, immersioni parziali, occlusioni e presenza contemporanea di più persone. Inoltre, poiché la prima fase della *pipeline* deve fornire sia la posizione sia la *silhouette* dei bagnanti, le annotazioni devono supportare l'addestramento e la sperimentazione sia nell'ambito della segmentazione di istanza sia in quello dell'*object detection*.

La disponibilità di raccolte pubbliche dedicate all'ambiente acquatico costituisce un importante punto di partenza, ma non elimina la necessità di acquisire materiale specifico per il problema considerato. Ad esempio, il *Water Behavior Dataset* proposto da Hasan *et al.* comprende riprese sopra e sotto la superficie e distingue tre attività, ossia *swimming*, *drowning* e *idle*; ogni filmato ritrae tuttavia un solo soggetto ed è organizzato principalmente per il riconoscimento dell'attività svolta [17]. Il presente lavoro richiede invece annotazioni a livello di istanza in scene con più persone, osservate da differenti inquadrature sopraelevate. Per questa ragione è stato realizzato un nuovo corpus video, dal quale sono stati derivati due *dataset*: il primo per YOLO-SEG, basato su maschere di segmentazione, e il secondo per YOLO Detection, ottenuto convertendo le stesse annotazioni in *bounding box*.

Il capitolo descrive dapprima la preparazione e lo svolgimento delle registrazioni, quindi le operazioni di *pre-processing* e il processo di annotazione. Vengono successivamente presentati i controlli di qualità, il criterio di suddivisione nei tre insiemi di *training*, *validation* e *test*, la conversione dal formato di segmentazione a quello di rilevazione e, infine, i principali vantaggi e limiti della raccolta realizzata.

3.1 Acquisizione del materiale video

3.1.1 Preparazione delle registrazioni

Prima dell'acquisizione è stato approfondito il fenomeno dell'annegamento, con particolare attenzione alle manifestazioni visive descritte nel Capitolo 1. Questa fase era necessaria per definire le situazioni da riprodurre e per spiegare ai figuranti i movimenti richiesti durante le simulazioni. Parallelamente è stata avviata la ricerca di una struttu-


ra che disponesse di una piscina adatta, di punti di installazione sopraelevati e delle autorizzazioni necessarie allo svolgimento delle riprese.




(a) Posizione delle sei telecamere presso l'impianto



Telecamera 1



Telecamera 2



Telecamera 3



Telecamera 4



Telecamera 5



Telecamera 6

(b) Esempi delle inquadrature ottenute

Figura 3.1: Configurazione delle telecamere presso il Polo Natatorio San Pietro ed esempi dei sei punti di vista utilizzati per le registrazioni

La ricerca è iniziata il 2 gennaio 2026 con un primo contatto con il Centro Natatorio di Mompiano. Il progetto è stato successivamente presentato al direttore generale di San Filippo S.p.A., società incaricata della gestione dei centri sportivi del Comune di Brescia. La procedura ha richiesto la predisposizione di documentazione destinata ai *Data Protection Officer* di San Filippo S.p.A., della Federazione Italiana Nuoto e del Comune di Brescia. L'attenzione riservata alle autorizzazioni deriva dalla natura delle registrazioni, nelle quali i partecipanti costituiscono soggetti identificabili e le immagini devono pertanto essere trattate nel rispetto dei principi applicabili alla protezione dei dati personali [24].

Il riscontro favorevole dei primi due enti non è stato accompagnato dall'autorizzazione del Comune; si è quindi reso necessario individuare un'altra sede. La disponibilità è stata ottenuta dal Polo Natatorio San Pietro di Castiglione delle Stiviere e dal Parco Acquatico Cavour di Valeggio sul Mincio. Dopo l'analisi delle planimetrie, dei possibili punti di installazione delle telecamere e delle disponibilità dei figuranti, è stato scelto il primo impianto. Il giorno precedente alle registrazioni sono state effettuate prove preliminari per stabilire la posizione dei dispositivi e regolare l'esposizione e il bilanciamento del bianco.

3.1.2 Configurazione e contenuto delle riprese

Le registrazioni sono state svolte la mattina del 31 maggio 2026 presso la piscina esterna da 50 metri del Polo Natatorio San Pietro. La vasca comprende due zone con profondità rispettivamente pari a 1,50 e 2,20 metri. Hanno partecipato undici volontari dotati di buone capacità natatorie, così da poter rappresentare sia attività ordinarie sia le situazioni simulate previste per la raccolta.

Per l’acquisizione sono state impiegate sei ICEFOX i8 Action Camera 4K, configurate alla risoluzione di 1920×1080 *pixel* e a 30 *frame* al secondo. Le telecamere sono state collocate in corrispondenza dei piloni della struttura adiacente alla piscina. La disposizione ha prodotto sei inquadrature sopraelevate e differenti della vasca, coerenti con la configurazione multicamera prevista dal sistema di riferimento. La Figura 3.1 mostra la posizione dei dispositivi e un fotogramma rappresentativo per ciascun punto di vista.

Il materiale comprende normali situazioni di utilizzo della piscina, quali il nuoto, il gioco, anche con un pallone, e i tuffi. A queste attività sono state affiancate simulazioni di annegamento attivo e passivo. Le azioni non costituiscono classi del *dataset* descritto in questo capitolo: la loro funzione è introdurre varietà visiva nelle posture, nei movimenti, nel grado di immersione e nelle interazioni tra i soggetti. L’annotazione riguarda infatti esclusivamente la presenza delle persone e non il loro stato comportamentale.

3.2 Pre-processing dei filmati

Le registrazioni grezze comprendevano, oltre alle sequenze destinate al *dataset*, filmati utilizzati per definire l’inquadratura e riprese della sola piscina vuota. La prima operazione è consistita quindi nella selezione del materiale utile, escludendo i video realizzati unicamente per la configurazione delle telecamere o privi di soggetti per l’intera durata.

I filmati selezionati sono stati suddivisi in clip uniformi di 60 secondi. Alla frequenza originale di acquisizione, ogni clip conteneva pertanto 1800 fotogrammi. La durata costante ha semplificato le elaborazioni successive, consentendo di trattare unità omogenee e di mantenere l’origine temporale di ciascun gruppo di immagini.

Il posizionamento fisico delle *action camera* aveva prodotto filmati ruotati; a ogni clip è stata quindi applicata una rotazione di 180° . Successivamente la frequenza è stata ridotta da 30 a 10 fotogrammi al secondo, mantenendo la risoluzione di 1920×1080 *pixel* e impostazioni di esportazione coerenti con la qualità e il fattore di compressione del materiale originale. Dopo il *downsampling*, una clip di 60 secondi risulta composta nominalmente da 600 immagini. La riduzione limita il costo di annotazione e addestramento, conservando comunque una frequenza temporale sufficiente a rappresentare l’evoluzione visiva delle azioni considerate.

È stata inoltre applicata una trasformazione geometrica per correggere la distorsione introdotta dalla curvatura della lente. Tale operazione è particolarmente importante nelle zone periferiche dell’immagine, nelle quali la distorsione delle linee e delle proporzioni dei soggetti risulta più evidente. Il confronto riportato nella Figura 3.2 rende visibili sia il riorientamento del fotogramma sia la successiva correzione geometrica. Infine, le

clip sono state rinominate mediante identificativi numerici progressivi, ottenendo una nomenclatura uniforme per le successive conversioni e revisioni.



Figura 3.2: Confronto sullo stesso fotogramma tra la ripresa originale, il risultato della rotazione e quello della correzione della distorsione della lente

Al termine delle operazioni di selezione e dei controlli svolti durante l’annotazione sono rimaste 172 clip. Il *dataset* finale comprende 91 410 immagini nelle quali è visibile almeno una persona associata a un’annotazione. I fotogrammi contenenti esclusivamente lo sfondo non sono stati inclusi nell’insieme finale.

3.3 Realizzazione del dataset YOLO-SEG

3.3.1 Generazione automatica delle maschere

La segmentazione manuale di oltre novantamila immagini avrebbe richiesto un’attività difficilmente sostenibile. È stato pertanto adottato un procedimento semiautomatico, nel quale un modello ha prodotto le annotazioni iniziali e l’intervento umano si è concentrato sulla verifica e sulla correzione degli errori.

Le clip elaborate sono state trasferite su una macchina virtuale fornita da RunPod¹ ed equipaggiata con una GPU NVIDIA RTX 4090 dotata di 24 GB di memoria video. Su tale macchina è stato eseguito SAM 3, un modello basato su architettura *Transformer* per la segmentazione di istanza e il tracciamento di oggetti in immagini e video [19]. Nel procedimento adottato, il modello è stato impiegato per generare automaticamente le maschere di segmentazione e propagarle lungo i fotogrammi delle clip. Il ricorso alla GPU ha reso possibile elaborare l’intera raccolta senza eseguire manualmente il contorno di ciascuna istanza in ogni immagine.

Le annotazioni prodotte automaticamente sono state successivamente esportate e convertite, mediante uno *script* Python, nel formato CVAT for video 1.1 [21]. Questa rappresentazione intermedia è stata scelta per consentire l’importazione delle maschere in CVAT, uno strumento *open source* per l’annotazione e la revisione di immagini e video [20], e la loro correzione attraverso un’interfaccia dedicata. L’applicazione è stata eseguita localmente all’interno di un contenitore Docker, così da disporre di un ambiente riproducibile per l’ispezione delle sequenze. La Figura 3.3 riassume il procedimento seguito fino all’esportazione finale.

¹RunPod è una piattaforma *cloud* che fornisce accesso su richiesta a risorse GPU e CPU per applicazioni di intelligenza artificiale e altri carichi computazionali intensivi [22].




Figura 3.3: Processo di annotazione, dalla clip pre-processata alla generazione automatica delle maschere, alla revisione in CVAT e all’esportazione nel formato YOLO Segmentation

3.3.2 Definizione della classe

Il compito di segmentazione è stato formulato come problema a classe singola. L’unica classe, denominata **person**, comprende tutte le persone visibili nell’immagine, indipendentemente dalla loro posizione dentro o fuori dalla vasca e dall’attività svolta. Ogni soggetto visibile costituisce un’istanza distinta e possiede quindi una propria maschera.

Questa scelta mantiene separata la rilevazione dalla successiva interpretazione del comportamento. L’etichetta non distingue il nuoto, il gioco, il tuffo o le simulazioni di crisi e non codifica il grado di immersione. Il *dataset* fornisce esclusivamente l’informazione spaziale necessaria a individuare le persone e, nella versione di segmentazione, a descriverne la *silhouette*. Le eventuali valutazioni sullo stato del soggetto appartengono alle fasi successive della *pipeline* e non rientrano nel processo di annotazione qui trattato.

3.3.3 Revisione e controllo della qualità

Le maschere generate automaticamente non presentavano una qualità uniforme. Gli errori principali riguardavano segmentazioni parziali, contorni frammentati e associazioni temporali errate tra soggetti vicini. Tutte le clip sono state pertanto sottoposte a una prima revisione manuale in CVAT, durante la quale sono state corrette le maschere non aderenti alla persona visibile e le sequenze nelle quali il tracciamento automatico aveva confuso le istanze.

Alcuni filmati presentavano errori troppo estesi per poter essere corretti con un livello di affidabilità adeguato nel tempo disponibile e sono stati esclusi dalla raccolta. Sulle annotazioni rimanenti è stato poi eseguito uno *script* per unire le porzioni disconnesse appartenenti alla stessa maschera mediante un’operazione di chiusura morfologica implementata con OpenCV. La chiusura, ottenuta applicando in successione una dilatazione e un’erosione, permette di colmare piccole interruzioni e di ricomporre regioni che il modello aveva separato pur appartenendo allo stesso soggetto [23].

Le annotazioni così elaborate sono state sottoposte a un secondo controllo visivo. La verifica ha considerato la corrispondenza tra la maschera e la persona, la continuità delle regioni, la separazione delle istanze nelle situazioni di contatto e la coerenza lungo fotogrammi consecutivi. Il controllo in due passaggi, unito all’esclusione dei casi più problematici, ha ridotto gli errori più evidenti; non garantisce tuttavia che ogni contorno presenti lo stesso livello di precisione. La Figura 3.4 mostra un esempio reale di correzione. Come discusso nella Sezione 3.6, il tempo disponibile ha imposto un compromesso tra estensione della raccolta e accuratezza puntuale di tutte le maschere.



Figura 3.4: Esempio di controllo della qualità: confronto tra il fotogramma originale, le maschere generate automaticamente da SAM 3 e l’annotazione finale ottenuta dopo la revisione manuale. Le istanze non individuate durante la generazione automatica sono state aggiunte sulla base delle persone visibili

3.3.4 Esportazione nel formato YOLO Segmentation

Dopo il secondo controllo, le annotazioni sono state convertite nel formato Ultralytics YOLO Segmentation 1.0 [21]. A ogni immagine è associato un file di testo contenente una riga per ciascuna persona visibile. La riga riporta l’identificativo della classe seguito dalle coordinate normalizzate dei vertici del poligono che approssima il contorno dell’istanza. Poiché il problema comprende la sola classe **person**, tutte le istanze condividono lo stesso identificativo di classe, mentre rimangono separate attraverso i rispettivi poligoni. Il Listato 3.1 riporta integralmente una riga reale estratta dal *dataset*.

```
0 0.203646 0.119444 0.197396 0.119444 0.195312 0.120370 0.193750 0.121296 0.192708
0.123148 0.191667 0.126852 0.191667 0.172222 0.201042 0.229630 0.214583 0.304630
0.216146 0.312037 0.219792 0.325000 0.220312 0.325000 0.250521 0.302778 0.252604
0.300926 0.253125 0.297222 0.253125 0.190741 0.252083 0.188889 0.205208 0.121296
```

Listato 3.1: Riga completa relativa all’istanza 5 del fotogramma 482 del video 126 nel formato YOLO Segmentation

La rappresentazione ottenuta conserva l’informazione geometrica necessaria a ricostruire una maschera per ogni soggetto. Essa risponde quindi alle esigenze del modulo YOLO-SEG e mantiene la compatibilità con le fasi successive di DEWS, nelle quali la forma segmentata viene utilizzata per ricavare proprietà geometriche e descrittori comportamentali [16].

3.4 Suddivisione nei set di training, validation e test

La forte correlazione temporale tra fotogrammi consecutivi rende inadeguata una suddivisione casuale eseguita a livello di singola immagine. Fotogrammi estratti dalla stessa clip potrebbero infatti risultare quasi identici e comparire sia nell’insieme di addestramento sia in quello di valutazione, producendo una stima eccessivamente ottimistica della capacità di generalizzazione del modello. Per evitare questa forma di contaminazione, la clip è stata assunta come unità minima indivisibile: tutti i suoi fotogrammi appartengono allo stesso insieme.

È stato introdotto anche un vincolo relativo al punto di vista. Le clip provenienti dalla medesima telecamera sono state assegnate a un solo insieme, in modo che una stessa inquadratura non comparisse contemporaneamente nel *training*, nella *validation* e nel *test*. In questo modo la valutazione richiede al modello di operare su punti di vista non osservati durante l'addestramento, riducendo la possibilità che le prestazioni dipendano dalla memorizzazione di uno specifico sfondo.

La ripartizione nominale adottata è pari al 70% per il *training*, al 10% per la *validation* e al 20% per il *test*. Applicando i vincoli di raggruppamento descritti, le 172 clip sono state distribuite come segue: 117 nel *training set*, 19 nel *validation set* e 36 nel *test set*. I tre insiemi risultano pertanto disgiunti sia rispetto alle clip sia rispetto alle inquadrature. La composizione risultante è riepilogata nella Tabella 3.1.

Tabella 3.1: Suddivisione delle clip e delle immagini nei tre insiemi del *dataset*

Insieme	Percentuale nominale	Percentuale effettiva	Clip	Immagini
<i>Training</i>	70%	66,83%	117	61 089
<i>Validation</i>	10%	11,81%	19	10 795
<i>Test</i>	20%	21,36%	36	19 526
Totale	100%	100%	172	91 410

Questa suddivisione è stata mantenuta invariata nella successiva conversione del *dataset*. Di conseguenza, le prestazioni dei modelli di segmentazione e di rilevazione possono essere confrontate sugli stessi fotogrammi e sui medesimi punti di vista, senza introdurre differenze dovute alla composizione degli insiemi di valutazione.

3.5 Conversione nel formato YOLO Detection

Il *dataset* per l'*object detection* è stato derivato direttamente da quello per YOLO-SEG, senza eseguire una nuova attività di annotazione. Per ciascuna maschera, uno *script* Python ha determinato i valori estremi delle coordinate del poligono e ha ricavato la più piccola *bounding box* assiale in grado di contenerlo. La regione è stata quindi espressa nel formato Ultralytics YOLO Detection 1.0 [21] mediante l'identificativo della classe e i quattro valori normalizzati relativi al centro, alla larghezza e all'altezza della *bounding box*. Il Listato 3.2 mostra la riga completa ottenuta dalla conversione della stessa istanza impiegata nel Listato 3.1.

```
0 0.222396 0.222222 0.061458 0.205556
```

Listato 3.2: Riga completa relativa all'istanza 5 del fotogramma 482 del video 126 nel formato YOLO Detection

La conversione modifica esclusivamente la rappresentazione spaziale dell'istanza. La classe rimane **person**, il numero di immagini utili resta pari a 91 410 e l'assegnazione ai tre insiemi di *training*, *validation* e *test* non cambia. I due *dataset* estesi condividono quindi esattamente i fotogrammi di ingresso e differiscono soltanto per il livello di

dettaglio dell’annotazione: il contorno poligonale nel caso di YOLO-SEG e il rettangolo di delimitazione nel caso di YOLO. La Figura 3.5 visualizza tale differenza sullo stesso fotogramma.




Figura 3.5: Confronto sullo stesso fotogramma tra i poligoni del *dataset* YOLO-SEG e le *bounding box* del *dataset* YOLO Detection

L’origine comune delle annotazioni consente un confronto controllato tra i due compiti. Gli errori grossolani di localizzazione presenti in una maschera possono propagarsi anche alla relativa *bounding box*; le piccole irregolarità del contorno hanno invece un’incidenza minore sulla rappresentazione rettangolare. Il *dataset* di *detection* risulta pertanto meno ricco dal punto di vista geometrico, ma anche meno dipendente dalla precisione puntuale del bordo segmentato.

3.6 Vantaggi e limiti del dataset

Il principale vantaggio della raccolta è la sua estensione. Le 91 410 immagini annotate permettono di osservare la classe **person** in numerose configurazioni, con soggetti isolati o ravvicinati, differenti posture e diversi livelli di immersione. La presenza di sei inquadrature introduce inoltre variazioni di scala, prospettiva e porzione di vasca osservata. Questi elementi assumono particolare importanza in un sistema destinato a operare in un ambiente nel quale l’aspetto del soggetto cambia rapidamente a causa dell’acqua e del movimento.

Un secondo vantaggio riguarda il realismo delle scene. Le registrazioni non comprendono soltanto simulazioni controllate di annegamento, ma anche nuoto, tuffi, gioco e interazioni tra più partecipanti. Schizzi, riflessi, palloni, bandiere e occlusioni costituiscono sorgenti di difficoltà, ma rappresentano anche condizioni plausibili durante l’utilizzo ordinario di una piscina. La complessità del materiale riduce quindi la distanza tra le immagini di addestramento e il contesto applicativo previsto. Alcune delle condizioni visive rappresentate nella raccolta sono riportate nella Figura 3.6.




Figura 3.6: Esempi rappresentativi della variabilità del *dataset* in termini di affollamento, postura, interazione con l’acqua, presenza di oggetti e posizione dei soggetti

La raccolta presenta tuttavia alcuni limiti. Il primo riguarda la qualità non uniforme delle maschere. L’annotazione automatica ha consentito di raggiungere una dimensione elevata, ma ha prodotto errori e segmentazioni parziali che non è stato possibile correggere integralmente nel tempo disponibile. Il controllo manuale e la chiusura morfologica hanno migliorato le annotazioni, senza eliminare ogni imprecisione nei contorni più complessi.

Un secondo limite è la possibile ridondanza temporale. Il campionamento a 10 fotogrammi al secondo produce immagini consecutive molto simili, soprattutto quando i soggetti si muovono lentamente. La separazione per clip impedisce che tale somiglianza contaminino insieme differenti, ma non elimina la correlazione interna al *training set*. Una quantità elevata di immagini non corrisponde quindi necessariamente allo stesso numero di configurazioni indipendenti.

Infine, tutte le registrazioni sono state realizzate in una sola giornata e in un unico impianto. Le sei telecamere offrono punti di vista differenti, ma condividono la medesima piscina, le stesse condizioni generali di illuminazione e lo stesso contesto architettonico. La capacità del modello di generalizzare a piscine con colori, profondità, coperture e illuminazioni differenti deve pertanto essere verificata separatamente.

Nel complesso, i due *dataset* ottenuti costituiscono una base sperimentale comune per l’addestramento e il confronto dei modelli dedicati alla segmentazione di istanza e all’*object detection*, pur con i limiti di rappresentatività e qualità delle annotazioni appena discussi. Il capitolo successivo descrive il processo di *fine-tuning* dei modelli YOLO e ne analizza le prestazioni, con particolare attenzione al confronto tra le diverse taglie e all’idoneità per l’elaborazione in tempo reale.

Capitolo 4

Fine-tuning e Analisi dei Risultati

Il capitolo descrive il processo di *fine-tuning* applicato ai modelli YOLO impiegati per la rilevazione e la segmentazione dei bagnanti. L'obiettivo dell'analisi non consiste soltanto nell'individuare la configurazione con il valore più elevato di una singola metrica, ma nel valutare congiuntamente la capacità di localizzazione, la completezza delle rilevazioni e il costo computazionale. Quest'ultimo aspetto assume particolare importanza perché il modello è destinato a sostituire il primo stadio di una *pipeline* che deve elaborare continuamente più flussi video.

Gli esperimenti considerati nel seguito utilizzano esclusivamente il *dataset* descritto nel Capitolo 3. I risultati riguardano due compiti distinti: l'*object detection*, nel quale ogni bagnante è rappresentato mediante una *bounding box*, e la segmentazione di istanza, nella quale YOLO-SEG produce anche una maschera della *silhouette*. Questa distinzione viene mantenuta in tutta l'analisi, poiché le metriche riferite alle regioni rettangolari e quelle calcolate sulle maschere non sono direttamente intercambiabili.

4.1 Selezione del modello e delle taglie

Per la sperimentazione è stata adottata la famiglia YOLO26, utilizzando i pesi pre-addestrati messi a disposizione per i compiti di *detection* e di segmentazione. Il ricorso a pesi pre-addestrati consente di inizializzare la rete con rappresentazioni visive già apprese su un insieme di dati generale e di adattarle successivamente al dominio specifico della piscina. Il *fine-tuning* deve quindi specializzare il modello rispetto alla classe **person**, alle riprese sopraelevate e alle condizioni visive introdotte dall'acqua, senza dover apprendere da zero tutte le caratteristiche di basso livello.

Sono state considerate tre taglie della stessa famiglia:

- *nano* (N), caratterizzata dal costo computazionale più contenuto;
- *small* (S), scelta come configurazione intermedia;
- *medium* (M), dotata di una capacità maggiore ma anche di un tempo di inferenza superiore.

L'impiego di taglie differenti permette di verificare se l'aumento della capacità del modello produca un miglioramento sostanziale rispetto al relativo incremento di latenza.

Non tutte le combinazioni pianificate hanno però generato un addestramento completo e un insieme equivalente di artefatti. Per la prima configurazione sono disponibili i modelli S e M per la *detection* e N, S e M per la segmentazione; per la seconda configurazione sono disponibili S e M per la *detection* e S per la segmentazione. Il confronto viene pertanto svolto soltanto sulle esecuzioni per le quali è presente un *checkpoint* valutabile, senza ricostruire risultati mancanti.

Tutti i valori riportati nel seguito si riferiscono a immagini ridimensionate a 640×640 *pixel*. La configurazione iniziale prevedeva la possibilità di ripetere gli esperimenti anche a 960 e 1280 *pixel*; tali prove non compaiono tuttavia nei *log* e nel riepilogo di valutazione disponibili. Non vengono quindi formulate conclusioni sull'effetto della risoluzione di ingresso.

4.2 Configurazione del processo di fine-tuning

Gli addestramenti sono stati eseguiti utilizzando sia una macchina del Dipartimento di Ingegneria dell'Informazione dotata di GPU NVIDIA A100 SXM4 con 80 GB di memoria, sia la piattaforma di addestramento di Ultralytics. Poiché i *run* sono stati distribuiti fra ambienti differenti e alcuni di essi sono stati interrotti, il tempo totale di addestramento non viene utilizzato come criterio per confrontare le taglie. La valutazione finale è stata invece ripetuta in modo uniforme sul medesimo *test set* e con la stessa dimensione di ingresso.

Per ogni esecuzione è stato utilizzato un modello pre-addestrato. Il numero massimo di epoche è stato fissato a 150, con *early stopping* dopo 30 epoche consecutive prive di un miglioramento della funzione di validazione impiegata dal processo di addestramento. Il *batch size* effettivo, verificato nei file `args.yaml` dei diversi *run*, è pari a 16. L'addestramento è stato eseguito con *Automatic Mixed Precision* (AMP), così da ridurre l'occupazione di memoria e sfruttare operazioni a precisione ridotta quando compatibili.

La riproducibilità è stata favorita impostando il *seed* a 0 e abilitando l'esecuzione deterministica. Ciò riduce le variazioni introdotte dalla casualità, pur non garantendo necessariamente un'identità bit a bit fra piattaforme, versioni delle librerie e dispositivi differenti. È stata utilizzata l'intera frazione del *training set*; non sono stati abilitati né il *multi-scale training* né il caricamento in modalità rettangolare. La dimensione di ingresso è rimasta quindi costante durante ciascun esperimento.

La pianificazione del *learning rate* non utilizza un andamento cosinusoidale. Sono previste tre epoche di *warm-up*, con *warm-up momentum* pari a 0,8 e *warm-up bias learning rate* pari a 0,1. Il fattore finale del *learning rate*, indicato dal parametro `lrf`, è pari a 0,01, mentre il *weight decay* è fissato a 0,0005. Il parametro `close_mosaic` è impostato a 10, con l'intenzione di disabilitare l'augmentazione *mosaic* nelle ultime dieci epoche del piano completo; i *run* terminati anticipatamente possono tuttavia non avere raggiunto questa fase.

I coefficienti principali della funzione obiettivo sono stati mantenuti invariati nelle due configurazioni: 7,5 per la componente di localizzazione delle *bounding box*, 0,5 per la classificazione e 1,5 per la *Distribution Focal Loss*. Gli ulteriori parametri relativi a compiti non utilizzati, quali la stima della posa, non intervengono nella scelta fra i modelli analizzati.

4.2.1 Prima configurazione

La prima configurazione affida alla modalità automatica della libreria la scelta dell'ottimizzatore, indicata nei file di esecuzione mediante `optimizer: auto`. Negli appunti sperimentali la selezione risultante è riportata come MuSGD. Il *learning rate* iniziale configurato è pari a 0,01 e nessuno strato viene congelato: l'ottimizzazione può quindi modificare l'intera rete sia nel compito di *detection* sia in quello di segmentazione.

Questa impostazione costituisce il primo riferimento per misurare il beneficio del *fine-tuning*. L'assenza di congelamento offre al modello la massima libertà di adattamento, ma espone anche tutte le rappresentazioni pre-addestrate agli aggiornamenti prodotti dal nuovo dominio. In presenza di un *learning rate* relativamente elevato, l'evoluzione delle metriche di validazione deve pertanto essere controllata insieme alle *loss* di addestramento.

4.2.2 Seconda configurazione

La seconda configurazione introduce tre modifiche principali. L'ottimizzatore viene impostato esplicitamente ad AdamW, il *learning rate* iniziale viene ridotto da 0,01 a 0,0001 e, per i modelli di *detection*, vengono congelati i primi dieci strati. In questo modo la parte iniziale della rete conserva le rappresentazioni pre-addestrate, mentre gli strati successivi vengono adattati al nuovo dominio con aggiornamenti più contenuti.

Nel caso di YOLO-SEG il congelamento non è stato applicato, come confermato dal valore `freeze: null` nei file di configurazione. Tale differenza è necessaria per interpretare correttamente i risultati: il confronto fra le due configurazioni di segmentazione non isola soltanto l'effetto dell'ottimizzatore, ma riguarda l'insieme dei parametri effettivamente impiegati. Tutte le altre impostazioni comuni, comprese le 150 epoche massime, la pazienza pari a 30, il *batch size* pari a 16 e la risoluzione di 640 *pixel*, restano invariate.

4.3 Tecniche di data augmentation

Il *dataset* presenta condizioni visive complesse, ma proviene da un unico impianto e da una sola giornata di acquisizione. La *data augmentation* è stata quindi utilizzata per aumentare la variabilità osservata durante l'addestramento senza modificare il contenuto semantico delle immagini. Le trasformazioni sono state mantenute relativamente moderate, così da non generare geometrie incompatibili con la scena reale.

Le variazioni cromatiche agiscono nello spazio HSV. L'ampiezza configurata è pari a 0,015 per la tonalità, 0,4 per la saturazione e 0,3 per la luminosità. Queste trasformazioni simulano parzialmente variazioni dell'illuminazione, della risposta della telecamera e dell'aspetto dell'acqua. Dal punto di vista geometrico vengono applicate rotazioni fino a 5 gradi, traslazioni fino al 5% della dimensione dell'immagine e variazioni di scala pari a 0,3. *Shear* e trasformazioni prospettiche sono disabilitate.

Il ribaltamento orizzontale viene applicato con probabilità 0,5, mentre quello verticale è disabilitato. La scelta è coerente con la struttura della scena: una riflessione orizzontale conserva una configurazione plausibile della vasca, mentre un'immagine capovolta verticalmente non rappresenterebbe un punto di vista operativo realistico.

L'augmentazione *mosaic* è utilizzata con probabilità 0,5; *mixup* non viene applicato. Nella prima configurazione il parametro *copy-paste*, rilevante soprattutto per il compito di segmentazione, è posto a 0,1, mentre nella seconda configurazione è disabilitato.

L'augmentazione aumenta la varietà dei campioni, ma non sostituisce la raccolta di dati in nuovi impianti. In particolare, non introduce realmente differenti materiali della vasca, condizioni meteorologiche, configurazioni delle corsie o prospettive di ripresa. La capacità di generalizzare al di fuori del sito di acquisizione resta quindi un aspetto da verificare con un insieme di dati esterno.

4.4 Protocollo e metriche di valutazione

Durante l'addestramento il *validation set* viene utilizzato per controllare l'evoluzione del modello e per conservare il *checkpoint* migliore. La valutazione conclusiva viene invece eseguita sul *test set*, mantenuto separato sia rispetto alle clip sia rispetto alle inquadrature impiegate negli altri insiemi, come descritto nel Capitolo 3. Tutte le metriche finali presenti nel file `evaluation_summary.csv` sono calcolate a partire dai pesi `best.pt` dei rispettivi *run*.

La precisione misura la quota di predizioni positive che corrisponde a un'istanza annotata. Indicando con TP i veri positivi e con FP i falsi positivi, essa è definita come

$$\text{Precision} = \frac{TP}{TP + FP}. \quad (4.1)$$

Il *recall* misura invece la quota di istanze annotate che il modello riesce a rilevare. Indicando con FN i falsi negativi, si ha

$$\text{Recall} = \frac{TP}{TP + FN}. \quad (4.2)$$

Le due misure descrivono errori differenti. Una precisione ridotta segnala un numero maggiore di rilevazioni spurie, mentre un *recall* ridotto indica la perdita di istanze reali. Nel contesto della *pipeline*, una mancata rilevazione può interrompere o rendere meno stabile la traccia di un bagnante; la precisione deve tuttavia rimanere elevata per evitare che riflessi, schizzi o oggetti presenti in vasca vengano propagati alle fasi successive.

L'*Average Precision* (AP) riassume l'andamento della precisione rispetto al *recall* al variare della soglia di confidenza. Una predizione viene considerata corretta quando la sua *Intersection over Union* con l'annotazione supera la soglia stabilita. La metrica mAP_{50} utilizza una soglia IoU pari a 0,50, mentre $\text{mAP}_{50:95}$ media i risultati ottenuti per soglie comprese tra 0,50 e 0,95, con incremento pari a 0,05. Quest'ultima metrica penalizza maggiormente le localizzazioni imprecise. Poiché il *dataset* contiene una sola classe, la media fra classi coincide di fatto con l'AP della classe `person`; viene mantenuta la denominazione mAP adottata dallo strumento di valutazione.

Per i modelli di *detection*, l'IoU è calcolata sulle *bounding box*; per YOLO-SEG le metriche riportate nel riepilogo sono invece quelle delle maschere. I valori dei due compiti non devono pertanto essere confrontati come se misurassero lo stesso oggetto geometrico. Una maschera deve riprodurre un contorno più dettagliato e viene valutata a livello di regione segmentata, mentre una *bounding box* rappresenta soltanto il rettangolo che racchiude l'istanza.

Il tempo di inferenza è espresso in millisecondi per immagine. Dal suo reciproco è stato ricavato un *throughput* teorico

$$\text{FPS}_{\text{teorici}} = \frac{1000}{t_{\text{inf}}}, \quad (4.3)$$

dove t_{inf} è il tempo medio di inferenza in millisecondi. Tale valore descrive esclusivamente l'esecuzione del modello nell'ambiente di valutazione e non comprende necessariamente acquisizione, decodifica, *pre-processing*, associazione delle tracce, calcolo dei descrittori e comunicazione con gli altri componenti.

4.5 Analisi del processo di addestramento

L'analisi delle curve disponibili mostra comportamenti differenti fra le due configurazioni. Il numero massimo di 150 epoche costituisce un limite superiore, non il numero effettivamente eseguito da ogni *run*. I modelli N di segmentazione, S di *detection* e S di segmentazione della prima configurazione registrano 31 epoche: in tutti e tre i casi il massimo della $\text{mAP}_{50:95}$ di validazione compare alla prima epoca e le successive 30 epoche non producono un miglioramento sufficiente, determinando l'*early stopping*.

Le *loss* di addestramento continuano generalmente a diminuire, mentre le metriche di validazione oscillano o si riducono dopo il massimo iniziale. Questo andamento segnala che la prosecuzione dell'ottimizzazione non migliora la capacità misurata sull'insieme di validazione. È compatibile con un adattamento eccessivo ai dati di *training* o con aggiornamenti iniziali poco stabili, ma i soli *log* non permettono di attribuire il comportamento a una causa unica. Il *checkpoint* migliore evita comunque di utilizzare direttamente i pesi dell'ultima epoca.

Il grafico disponibile per YOLO26-M Detection nella prima configurazione mostra a sua volta 31 epoche. Dopo oscillazioni marcate nelle prime iterazioni, le *loss* di addestramento diminuiscono regolarmente; le metriche di validazione recuperano soltanto in parte e restano inferiori al massimo iniziale. Per questo *run* non è presente il corrispondente file `results.csv`, ma è disponibile il *checkpoint* migliore e la relativa valutazione sul *test set*.

La configurazione AdamW produce l'andamento più convincente nel caso di YOLO26-M Detection. Il *run* disponibile comprende 93 epoche e la $\text{mAP}_{50:95}$ di validazione raggiunge il proprio massimo osservato alla settantacinquesima epoca, pari a circa 0,695. Il miglioramento distribuito su una parte più ampia dell'addestramento, rispetto ai massimi concentrati nella prima epoca della configurazione precedente, indica un processo più graduale per questa taglia.

YOLO26-S Detection con AdamW raggiunge invece il massimo osservato della $\text{mAP}_{50:95}$ all'ottava epoca e termina alla trentottesima, in accordo con una pazienza pari a 30. Il *run* AdamW di YOLO26-S-SEG contiene soltanto 13 epoche e raggiunge il massimo osservato alla terza. Quest'ultimo risultato deve essere interpretato con cautela, poiché gli appunti sperimentali documentano un'interruzione del server che ha impedito di completare correttamente alcune esecuzioni. Anche il *log* della prima configurazione YOLO26-M-SEG si arresta dopo 14 epoche. La presenza dei relativi *checkpoint* consente una valutazione sul *test set*, ma non dimostra che l'ottimizzazione abbia raggiunto la convergenza.

Nel complesso, le curve non giustificano l'affermazione che AdamW sia sempre superiore. Il beneficio più chiaro riguarda YOLO26-M Detection, mentre per la taglia S e per la segmentazione il confronto è più incerto. La valutazione finale deve quindi essere condotta separatamente per compito, taglia e configurazione.

4.6 Risultati sul test set

I risultati finali confrontano innanzitutto i pesi pre-addestrati originali, valutati senza adattamento al nuovo *dataset*, con i migliori *checkpoint* ottenuti dal *fine-tuning*. Le metriche vengono riportate in percentuale, mentre il tempo di inferenza rimane espresso in millisecondi per immagine. Gli scarti descritti nel testo sono espressi in punti percentuali, non come variazioni percentuali relative.

4.6.1 Object detection

Prima del *fine-tuning*, l'aumento della taglia produce un miglioramento regolare. YOLO26-N ottiene una $mAP_{50:95}$ del 39,53%, YOLO26-S del 47,89% e YOLO26-M del 54,65%. La taglia M raggiunge inoltre una precisione dell'88,47% e un *recall* del 74,62%. Il risultato mostra che i pesi originali sono già in grado di riconoscere molte persone, ma perdono una parte rilevante dei bagnanti e localizzano con minore accuratezza le istanze osservate nel nuovo dominio.

La prima configurazione di *fine-tuning* aumenta la $mAP_{50:95}$ di YOLO26-S dal 47,89% al 70,21%, con un incremento di 22,32 punti. Il *recall* passa dal 69,65% al 90,21%, mentre la precisione raggiunge il 92,55%. Per YOLO26-M la $mAP_{50:95}$ cresce dal 54,65% al 72,73% e il *recall* dal 74,62% al 90,89%. Il miglioramento coinvolge quindi sia la capacità di ritrovare le istanze sia la precisione della loro localizzazione.

Con la configurazione AdamW, YOLO26-S raggiunge una $mAP_{50:95}$ del 69,86%, valore molto vicino ma leggermente inferiore al 70,21% della prima configurazione. Per la taglia M si osserva invece il risultato migliore dell'intero insieme di modelli di *detection*: precisione del 93,70%, *recall* del 94,61%, mAP_{50} del 97,13% e $mAP_{50:95}$ del 74,28%. Rispetto al modello M non adattato, gli incrementi sono pari a 5,24 punti di precisione, 19,99 punti di *recall*, 12,65 punti di mAP_{50} e 19,63 punti di $mAP_{50:95}$.

Il confronto fra S e M evidenzia il consueto compromesso fra accuratezza e velocità. Il modello M con AdamW supera il migliore S di 1,15 punti in precisione, 4,40 punti in *recall*, 1,53 punti in mAP_{50} e 4,07 punti in $mAP_{50:95}$, ma richiede circa 2,86 ms invece di 1,48 ms per immagine. La taglia M rappresenta quindi la scelta orientata alla massima qualità della *detection*; la taglia S conserva un vantaggio quando il numero di flussi simultanei o l'hardware disponibile rendono prioritaria la latenza.

4.6.2 Segmentazione di istanza

Anche per YOLO-SEG i pesi originali migliorano al crescere della taglia. La $mAP_{50:95}$ delle maschere passa dal 38,99% della taglia N al 42,19% della S e al 48,04% della M. Il *recall* rimane però compreso fra il 65,59% e il 72,99%, indicando che una parte delle persone annotate non viene segmentata correttamente.

La prima configurazione produce un miglioramento consistente per tutte le taglie. YOLO26-N-SEG raggiunge una mAP_{50} del 95,37% e una $mAP_{50:95}$ del 62,99%, con un incremento di 24,00 punti nella metrica più restrittiva. YOLO26-S-SEG raggiunge rispettivamente il 96,65% e il 66,44%, mentre YOLO26-M-SEG ottiene il 96,98% e il 66,52%. La differenza fra S e M è quindi pari a soli 0,33 punti sulla mAP_{50} e 0,08 punti sulla $mAP_{50:95}$.

Il modello M conserva il valore assoluto più elevato anche per la precisione, pari al 93,88%, mentre il migliore *recall* appartiene alla taglia S con il 92,33%. Il passaggio da S a M non determina dunque un miglioramento uniforme di tutte le metriche. A fronte di risultati quasi equivalenti sulla qualità delle maschere, il tempo di inferenza aumenta da 1,82 ms a 3,93 ms per immagine.

L'esecuzione AdamW disponibile per la variante S di YOLO26-SEG ottiene una precisione dell'86,97%, un *recall* dell'89,90%, una mAP_{50} del 95,31% e una $mAP_{50:95}$ del 66,21%. Rispetto alla prima configurazione della stessa taglia, la $mAP_{50:95}$ diminuisce di soli 0,23 punti, ma precisione e *recall* sono inferiori. Considerata anche la disponibilità di sole 13 epoche nel relativo *log*, questo esperimento non fornisce evidenza sufficiente per preferire AdamW nel compito di segmentazione.

Per la segmentazione, YOLO26-M-SEG costituisce la scelta orientata alla massima precisione assoluta, ma YOLO26-S-SEG presenta il compromesso più favorevole. La riduzione di latenza è superiore al 50%, mentre la perdita sulla $mAP_{50:95}$ è inferiore a un decimo di punto. Anche la taglia N rimane un'opzione utile su dispositivi più limitati: rispetto alla S riduce il tempo da 1,82 ms a 1,11 ms, al costo di 3,45 punti di $mAP_{50:95}$.

4.6.3 Effetto complessivo del fine-tuning

Il *fine-tuning* migliora in modo netto tutte le taglie per le quali è disponibile un confronto con i pesi originali. Gli incrementi più evidenti riguardano il *recall* e la $mAP_{50:95}$, segno che l'adattamento non si limita ad aumentare il numero di rilevazioni, ma migliora anche la loro sovrapposizione con le annotazioni. L'effetto è particolarmente rilevante in un ambiente nel quale il corpo può essere parzialmente immerso, deformato visivamente dalla superficie e confuso con riflessi o schizzi.

Il tempo di inferenza rimane invece sostanzialmente invariato fra il modello originale e quello adattato della stessa taglia. Questo risultato è atteso, poiché il *fine-tuning* modifica i valori dei pesi ma non introduce nuovi strati né aumenta la risoluzione di ingresso. Le piccole differenze misurate, dell'ordine di pochi centesimi di millisecondo, non indicano una variazione strutturale del costo del modello e possono dipendere dalla normale variabilità della misura.

4.7 Idoneità per un'applicazione real-time

Il modello più lento fra quelli fine-tuned considerati è YOLO26-M-SEG, con un tempo medio di inferenza di 3,93 ms per immagine, equivalente a circa 254 *frame* al secondo se si considera esclusivamente l'inferenza. YOLO26-M Detection richiede 2,86 ms, mentre le taglie S si collocano approssimativamente fra 1,4 e 1,8 ms. Nell'ambiente hardware

utilizzato per la valutazione, tutti i modelli dispongono quindi di un margine ampio rispetto al ritmo di acquisizione dei flussi video considerato nel progetto.

Il numero teorico di FPS non coincide tuttavia con la frequenza raggiungibile dall'intero sistema. La *pipeline* deve gestire più telecamere e comprende trasferimento delle immagini, ridimensionamento, normalizzazione, filtraggio delle predizioni, costruzione delle maschere, *tracking* e calcolo dei descrittori. Inoltre, i tempi riportati sono legati al dispositivo usato per la valutazione e non possono essere trasferiti direttamente a una GPU differente o a un sistema *edge*.

Di conseguenza, i risultati dimostrano che l'inferenza del modello non costituisce, sull'hardware di prova, un ostacolo al funzionamento in tempo reale. Non costituiscono invece una misura completa della latenza *end-to-end*. La verifica definitiva richiede un *benchmark* della *pipeline* integrata, con tutti i flussi video attivi, includendo sia i tempi medi sia i valori di coda che descrivono i fotogrammi elaborati più lentamente.

La scelta della taglia dipende infine dall'informazione richiesta dalle fasi successive. Se è sufficiente una regione rettangolare, YOLO26-M Detection con AdamW offre le metriche migliori e mantiene una latenza contenuta. Quando è necessaria la *silhouette* per calcolare area, orientamento e descrittori geometrici, YOLO26-S-SEG appare particolarmente favorevole: le sue metriche sono quasi equivalenti a quelle della taglia M, ma il tempo di inferenza è meno della metà. La compatibilità effettiva di queste uscite con il resto di DEWS viene esaminata nel capitolo successivo.

4.8 Considerazioni conclusive

La sperimentazione conferma l'utilità del *fine-tuning* sul dominio specifico. Rispetto ai pesi originali, i modelli adattati aumentano sensibilmente precisione, *recall* e mAP senza introdurre un costo di inferenza apprezzabile a parità di architettura. Il miglior risultato di *detection* è ottenuto dalla taglia M con AdamW, che raggiunge una mAP_{50:95} del 74,28% e un *recall* del 94,61%. Per la segmentazione, la taglia M della prima configurazione raggiunge il massimo assoluto, ma la taglia S offre un rapporto più favorevole fra qualità delle maschere e latenza.

L'analisi presenta comunque alcuni limiti. Le configurazioni non sono disponibili per tutte le combinazioni di taglia e compito, alcuni *run* sono stati interrotti e la sola risoluzione verificata è pari a 640 *pixel*. Il *test set* utilizza inquadrature escluse dall'addestramento, ma appartiene allo stesso impianto e alla stessa sessione generale di acquisizione. I risultati misurano pertanto la generalizzazione rispetto a punti di vista non osservati, non ancora quella verso piscine e condizioni ambientali completamente nuove.

Alla luce di questi vincoli, i risultati permettono di selezionare candidati adatti all'integrazione e di mostrare che il requisito temporale è plausibile sull'hardware di prova. Il passaggio successivo consiste nel verificare come le *bounding box* e, soprattutto, le maschere prodotte da YOLO-SEG possano alimentare il tracciamento e il calcolo dei descrittori comportamentali della *pipeline* esistente.

Capitolo 5

Integrazione nella Pipeline Esistente

Testo segnaposto.

Capitolo 6

Conclusioni

Testo segnaposto.

Bibliografia

- [1] Frank Pia. «Observations on the Drowning of Non-Swimmers». In: *The Journal of Physical Education* 71.6 (1974), pp. 164–167, 181.
- [2] Frank Pia. «The RID Factor as a Cause of Drowning». In: *Parks & Recreation* (giu. 1984), pp. 52–55, 67.
- [3] Frank Pia. «Reflections on Lifeguard Surveillance Programs». In: *Drowning: New Perspectives on Intervention and Prevention*. A cura di John R. Fletemeyer e Samuel J. Freas. Boca Raton, FL: CRC Press, 1999, pp. 231–243. ISBN: 9781574442236.
- [4] Frank Pia. *Guarding Against Misconceptions*. Aquatics International. 1 Mag. 2006. URL: https://www.aquaticsintl.com/facilities/guarding-against-misconceptions_o.
- [5] Frank Pia. *The Reasons People Drown*. Video recording. Larchmont, NY: L.S.A. Productions, Inc., 1988.
- [6] Pauline Gulliver e Dorothy J. Begg. «Usual Water-Related Behaviour and ‘Near-Drowning’ Incidents in Young Adults». In: *Australian and New Zealand Journal of Public Health* 29.3 (2005), pp. 238–243. DOI: 10.1111/j.1467-842X.2005.tb00761.x.
- [7] Aida Carballo-Fazanes, Joost J. L. M. Bierens e International Expert Group to Study Drowning Behaviour. «The Visible Behaviour of Drowning Persons: A Pilot Observational Study Using Analytic Software and a Nominal Group Technique». In: *International Journal of Environmental Research and Public Health* 17.18, 6930 (2020). DOI: 10.3390/ijerph17186930.
- [8] Luis-Miguel Pascual-Gomez e Lauren Petrass. «Recognition of a Drowning Victim by Bystanders: A Scoping Review». In: *International Journal of First Aid Education* 5.1 (2022), pp. 29–38. DOI: 10.25894/ijfae.5.1.6.
- [9] World Health Organization. *Drowning*. 1 Mag. 2026. URL: <https://www.who.int/news-room/fact-sheets/detail/drowning>.
- [10] Alessandro Massimo Nucara. *Rapporto sugli annegamenti nelle piscine italiane (2022–2026)*. Rapporto. Centro Studi Federalberghi, giu. 2026. URL: <https://www.federalberghi.it/download/download.aspx?file=571e73ff-5788-4523-9737-f30eddd57228&listId=f24d3693-761f-4a0a-a3db-7a35dd342fc1>.

- [11] Alvin H. Kam, Wenmiao Lu e Wei-Yun Yau. «A Video-Based Drowning Detection System». In: *Computer Vision – ECCV 2002*. A cura di Anders Heyden et al. Vol. 2353. Lecture Notes in Computer Science. Berlin e Heidelberg: Springer, 2002, pp. 297–311. DOI: 10.1007/3-540-47979-1_20.
- [12] How-Lung Eng et al. «An Automatic Drowning Detection Surveillance System for Challenging Outdoor Pool Environments». In: *Proceedings of the Ninth IEEE International Conference on Computer Vision*. Vol. 1. IEEE, 2003, pp. 532–539. DOI: 10.1109/ICCV.2003.1238393.
- [13] Wenmiao Lu e Yap-Peng Tan. «A Vision-Based Approach to Early Detection of Drowning Incidents in Swimming Pools». In: *IEEE Transactions on Circuits and Systems for Video Technology* 14.2 (2004), pp. 159–178. DOI: 10.1109/TCSVT.2003.821980.
- [14] How-Lung Eng et al. «Novel Region-Based Modeling for Human Detection within Highly Dynamic Aquatic Environment». In: *Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*. Vol. 2. IEEE, 2004, pp. 390–397. DOI: 10.1109/CVPR.2004.1315190.
- [15] How-Lung Eng et al. «Robust Human Detection within a Highly Dynamic Aquatic Environment in Real Time». In: *IEEE Transactions on Image Processing* 15.6 (2006), pp. 1583–1600. DOI: 10.1109/TIP.2006.871119.
- [16] How-Lung Eng et al. «DEWS: A Live Visual Surveillance System for Early Drowning Detection at Pool». In: *IEEE Transactions on Circuits and Systems for Video Technology* 18.2 (2008), pp. 196–210. DOI: 10.1109/TCSVT.2007.913960.
- [17] Saifeldin Hasan et al. «A Water Behavior Dataset for an Image-Based Drowning Solution». In: *2021 IEEE Green Energy and Smart Systems Conference (IGESSC)*. IEEE, 2021, pp. 101–105. DOI: 10.1109/IGESSC53124.2021.9618700.
- [18] Joseph Redmon et al. «You Only Look Once: Unified, Real-Time Object Detection». In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2016, pp. 779–788. DOI: 10.1109/CVPR.2016.91.
- [19] Nicolas Carion et al. *SAM 3: Segment Anything with Concepts*. 2025. DOI: 10.48550/arXiv.2511.16719. arXiv: 2511.16719 [cs.CV]. URL: <https://arxiv.org/abs/2511.16719>.
- [20] CVAT.ai Corporation. *Computer Vision Annotation Tool (CVAT)*. Ver. 2.25.0. 6 Nov. 2023. DOI: 10.5281/zenodo.4009388. URL: <https://github.com/cvat-ai/cvat>.
- [21] CVAT.ai Corporation. *Dataset Formats*. URL: https://docs.cvat.ai/docs/dataset_management/formats/.
- [22] RunPod. *Pods Overview*. URL: <https://docs.runpod.io/pods/overview>.
- [23] OpenCV. *More Morphology Transformations*. URL: https://docs.opencv.org/5.0/tutorials/imgproc/opening_closing_hats/opening_closing_hats.html.

- [24] Parlamento europeo e Consiglio dell'Unione europea. *Regolamento (UE) 2016/679 (Regolamento generale sulla protezione dei dati)*. Gazzetta ufficiale dell'Unione europea, L 119, pp. 1–88. 27 Apr. 2016. URL: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>.
- [25] International Electrotechnical Commission. *Degrees of Protection Provided by Enclosures (IP Code)*. 2.1. IEC 60529:1989+A1:1999. International Electrotechnical Commission. Geneva, feb. 2001.
- [26] UNI – Ente Italiano di Normazione. *Piscine pubbliche – Sistemi di visione computerizzata per la rilevazione di incidenti da annegamento nelle piscine – Requisiti di sicurezza e metodi di prova*. UNI EN ISO 20380:2018. Versione italiana pubblicata nel febbraio 2019 della norma EN ISO 20380:2017. UNI – Ente Italiano di Normazione. Milano, feb. 2019.

Ringraziamenti

In primo luogo, desidero ringraziare il mio relatore, il Dott. Alessandro Gnutti, per la costante disponibilità dimostrata durante l'intero processo di realizzazione di questo elaborato e, in particolare, per il prezioso aiuto nell'affrontare i numerosi problemi emersi nel corso degli esperimenti con le macchine virtuali, alcuni dei quali causati anche da me.

Un sincero ringraziamento va poi al Polo Natatorio San Pietro di Castiglione delle Stiviere, che ci ha accolti e ha messo a nostra disposizione i propri spazi, permettendoci di realizzare le riprese video necessarie al progetto.

Desidero inoltre ringraziare tutti coloro che hanno partecipato alle riprese in qualità di figuranti, dedicandoci il proprio tempo e contribuendo concretamente alla buona riuscita del lavoro: Davide Carasi, Lorenzo Guion, Francesca Simbeni, Elisabetta Milani, Jasmine Pizzichemi, Andrea Parolini, Leonardo Castelli, Niccolò Degl'Innocenti, Alice Alessio, Edoardo Alessio e Anna Alessio.

Un ringraziamento speciale va a Matteo Lucchini, dalla cui intuizione è nato questo progetto e che, più di chiunque altro, ha saputo supportarmi durante tutto il percorso.

Una menzione d'onore va anche al Parco Acquatico Cavour di Valeggio sul Mincio, che ci ha offerto la possibilità di effettuare le registrazioni presso la propria struttura. Purtroppo, per ragioni di tempo e di organizzazione, non ci è stato possibile approfittare della sua preziosa disponibilità.

Infine, ma non certo per importanza, ringrazio tutti i miei amici e i miei compagni di corso: da quelli che mi sono stati più vicini a quelli con cui ho condiviso anche soltanto qualche momento. Ognuno di loro, a modo proprio, ha contribuito a rendere questi tre anni un'esperienza indimenticabile.

*“Nessun bene è piacevole da possedere,
se non si ha qualcuno con cui dividerlo”*

— Seneca, *Lettere morali a Lucilio*, VI, 4